



מדעים דיגיטליים להיי-טק

פרוייקט בתעשייה בשיתוף Avertto דו"ח מסכם

מבצעים:

שם:	נועה גלבר	ת.ז.	206728313
שם:	עמית גביש	ת.ז.	207024027
שם:	עמית הדר	ת.ז.	318597721

ביצוע מקום הפרוייקט: **Avertto**

לשימוש המנחה:

הנני מאשר את הדו"ח המסכם המצורף

Stroke Alert LTD
סטרוק אלרט בע"מ
ח.פ. 516093580

שם: ד"ר הלה בן פזי מנכ"לית חתימה:

1. תקציר

המטרה של StrokeAlert היא לפתח ולספק מערכות להפחתת אירועי שבץ עבור אוכלוסיות בסיכון. החזון הוא לשפר את איכות החיים על ידי הפחתת השפעת שבץ שקט. StrokeAlert יפתחו, יצרו ויצילו את המכשיר הקל לשימוש הראשון להתרעת שבץ מוחי לאוכלוסיות בסיכון גבוה. החברה מכוונת לשני שווקים מרכזיים: 1. שוק בתי החולים- שימוש בחיישן במהלך ניתוחים בעלי סיכון להיסחפות קריש דם והיווצרות STROKE תוך כדי הניתוח כאשר הפציינט מורדם. 2. השוק הבייתי- שימוש בחיישן בשינה לאנשים בעלי סיכון גבוה, לאנשים שחוו שבץ יש סיכוי של 30% לקבל שבץ נוסף בחודשיים הקרובים שלאחר האירוע ו 10% לקבל שבץ נוסף בשנה החולפת. ההשפעה של StrokeAlert תהיה בזיהוי של השבץ וצמצום התמותה. כיום, לא קיים מוצר שיכול לזהות את השינויים הקליניים ההמודינמיים אצל אנשים מורדמים, כתוצאה מכך נפגעת יכולת הזיהוי והטיפול באירועים אלו. הייחודיות במוצר של SA הוא ביכולת לזהות שינויים המודינמיים בזרימת הדם במוח ובכך להתריע על היווצרות שבץ.

כפי שציינו בתכנית העבודה, היעד הסופי והמרכזי של החברה הוא לבנות מודל שיקבל נתוני דופק בזמן אמת וידע לזהות אם התרחשו שינויים ולהתריע במידה והוא מזהה שינוי המעיד על שבץ. מודל כזה צריך לדעת לזהות גל דופק סטנדרטי. לשם כך, יש לוודא שהמודל יאומן על נתונים באיכות הנדרשת, קרי, סיגנלים שעומדים בקריטריונים מוגדרים ונקיים מרעשים, ולמעשה מאפיינים גל דופק סטנדרטי באופן המיטבי.

מטרת העל שלנו בפרויקט היא לבנות מודל deep learning שידע לזהות אם הנתונים איכותיים מספיק. המודל שלנו ימפה את הדאטה שיועבר למודל "המזהה", ויאפשר לו להתאמן על נתונים נקיים ואיכותיים. בנוסף, המודל שלנו ידע להתמודד עם בעיית קליטת סיגנל מהחיישנים שנובעת מצורת הנחה ומיקום לא נכון של החיישן. השאיפה היא לדייק את היכולת לזהות את הסיגנל ואיכותו ולתת פידבק בזמן אמת על איכות הדאטה שהחיישן מקבל, ולהתריע על כך למשתמש.

2. שינויים בדרישות המערכת:

לא נדרשנו לשינויים משמעותיים, והמטרה הסופית של הפרויקט נשארה על כנה. עם זאת, כן חלו שינויים מסוימים:

- (1) בתכנית העבודה ציינו שהקיטועים (סגמנטים) עליהם נעבוד יהיו של 4 שניות, אך לבסוף תייגנו קיטועים של 2 שניות, לבקשת החברה. כל קיטוע כזה הוא למעשה מערך חד מימדי שמכיל 2000 ערכי y לאורך זמן, שמתארים את צורת הגל אותה אנו נדרשים לתייג.
- (2) בתכנית העבודה ציינו שגורמים נוספים מהחברה יצטרפו למטלת התיוגים על מנת ליצור דאטה מספיק גדול שנוכל לאמן עליו את המודלים. בזמן כתיבת התכנית ציינו שיהיו לנו סה"כ 4000 (1000 כל אחד + 1000 נוספים של החברה) קיטועים מתויגים לאמן את המודל עליהם, אך למעשה את המודל הראשוני אימנו על 19,500 קיטועים מתויגים.
- (3) בהמלצת החברה, את תוצאת ריצת המודל הטובה ביותר (האפוק שנותן את התוצאה הטובה ביותר) בחנו עם פונקציית $1f$.
- (4) לטובת המודל הראשוני, חילקנו את הדאטא למקטעי אימון ומקטעי ולידציה, ועדיין לא הקצנו דאטה גם לבחינה.

3. דיאגרמת בלוקים מפורטת:

1 למידת הממשק

חקר הנושא בתחום הרפואה,
הבנת הרעיון הטכנולוגי ולמידת
המושגים הטכניים הרלוונטיים

2 תיוג דאטא

מתן ציון ידני של 3x600 קיטועי
אקו-לב שנאספו במסגרת
מחקר החברה

3 הטעמה לColab

יצירת סביבה מתאימה ללמידת
מכונה וטעינת הדאטא שנאסף
עד כה בשיתוף עם החברה

4 מודלים

הרצת מודלים שונים של למידה
עמוקה (CNN) ובחינת ביצועם
שימוש בספריית Skleran

5 הערכת מודלים

ביצוע הערכה על המודלים השונים
שהרצנו, השוואה ביניהם בעזרת
מדדי טעויות וויזואליזציות של החיזוי
שביצעו חברת מודל אופטימלי

4. תוצרי הפרויקט:

תיוג הדאטה-

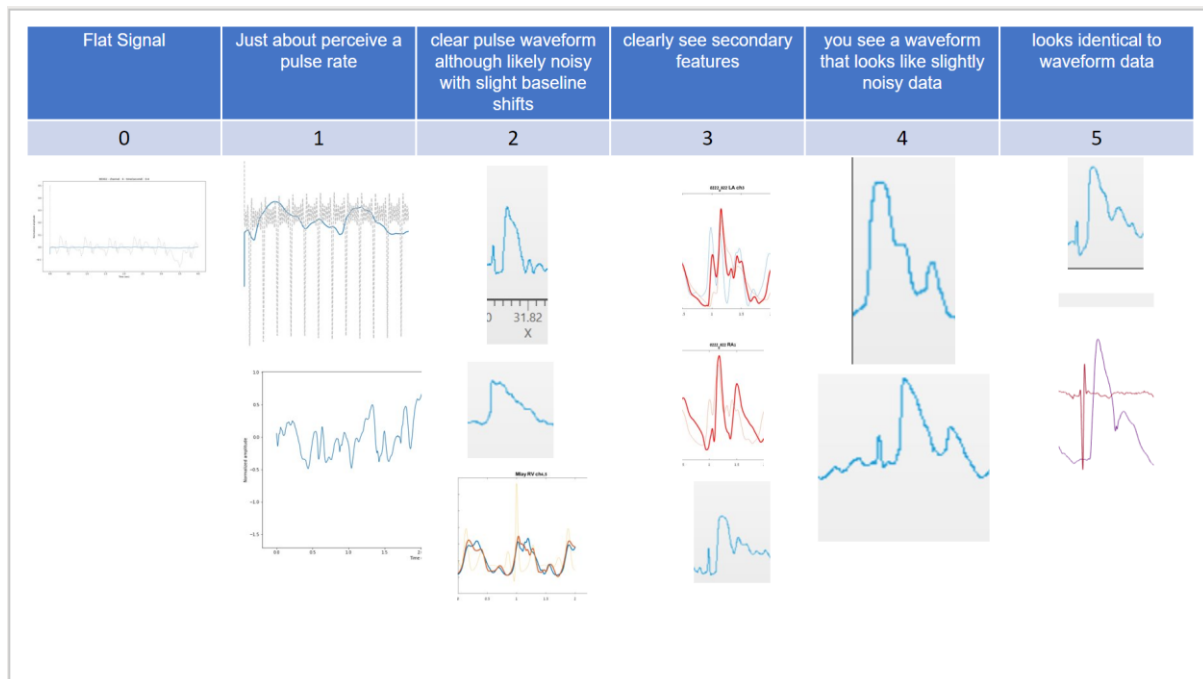
לצורך תיוג הדאטה, עברנו מספר ששנים עם גורמים מקצועיים מהחברה, על מנת שנוכל לתיוג את הדאטה בצורה המהימנה ביותר. כפי שציינו בתכנית העבודה, השתמשנו במערכת GUI, שהיא למעשה סביבה אינטרנטית שנקראת CVAT שהציגה לנו כל סגמנט כגל, ואנו נתנו לו ציון בין 0 (הכי פחות טוב) ל-5 (הכי טוב). היו לנו גם כמה גלים שסימנו כ"Flip", אם זיהינו שהם מופיעים בצורה הפוכה.

מצורף לצורך המחשה מדריך מטעם החברה שהנחה אותנו במשימת התיוג:


TABLE II
FIDUCIARY POINTS OF ARTERIAL PULSE WAVE USED FOR TRANSIT TIME MEASUREMENT

Fiducial point	Label	Description	Identification	Illustration
Waveform foot	A	Minimum amplitude of a pulse cycle between the start of the systole and end-diastole of its previous cycle.	(1) The minimum amplitude (absolute minima) point between the rear front of $P(t; x)$ and the forefront of its subsequent cycle. (2) The minima of a higher order polynomial fit into a search interval of $P(t; x)$ encompassing the foot region.	
Waveform peak	B	Maximum amplitude corresponding to the systolic peak pressure level.	The maximum amplitude (absolute maxima) of $P(t; x)$ in the systolic phase.	
First derivative maximum	C	A point on the original pulse cycle where its slope going into systolic peak pressure reaches a maximum.	The maximum point in the locus of the first derivative of $P(t; x)$ before its systolic peak.	
Second derivative maximum	D	A point on the original pulse cycle where its slope is changing fastest – a point corresponding onset of the systolic phase.	The maximum point in the locus of the second derivative of $P(t; x)$ before its systolic peak.	
Second derivative minimum	E	A point on the original pulse cycle where its slope is changing slowest – a point proximal to the systolic peak.	The minimum point in the locus of the second derivative of $P(t; x)$ before its systolic peak.	
Tangent intersection	F	The onset of the upstroke of the pulse cycle during systole.	The intersection of the tangent line to the maximum systolic upstroke with the horizontal line through the waveform minima.	
Dicrotic notch	G	The point in a pulse cycle representing the closure of the aortic valve, which occurs just moments after the start of diastole.	The maximum point in the locus of the second derivative of $P(t; x)$ subsequent to its systolic peak.	
Percentage pulse height	H	A point in the systolic upstroke of pulse cycle positioned at a fixed percentage of the maximum pulse height.	The last point moving from the waveform foot with an intensity value less than a specified threshold, a fixed percentage (say 25%) of the maximum pulse height) before the systolic peak.	


דוגמאות לתיוגים:



דוגמה ל"Flip" (איך יודעים? מיד אחרי הקו האפור שמסמל את העג, יש ירידה חדה במקום עליה)



התיוגים התבססו על המדריך שצירפנו, ועל מחזוריות הגל (בכל קיטוע אנו רואים בין 2-3 פיקים, עד כמה הפיקים דומים אחד לשני?). התמודדנו גם עם רעש (בסופו של דבר מדובר בגלי דופק של אנשים אמיתיים שחוברו אליהם סנסורים), ולמדנו לתייג גם גלים כאלה:



סיכום תיוגים

בשלב הראשון של הפרויקט (ינואר עד אפריל '23) הפקנו יחדיו 1800 תיוגים (בפועל קצת יותר), ויחד עם תיוגים נוספים של גורמים מהחברה לצורך הגדלת הדאטאבייס, מהווים את הבסיס לפרויקט עליו המודלים מתאמנים. לאחר עיבוד הדאטא, בניית המודלים המתאימים ואימונם, בשלב השני של הפרוייקט, הפקנו 900 תיוגים נוספים שקיבלנו מתוך הקלטות חדשות שביצעה החברה. במהלך העבודה על החלק השני של התיוגים התרשמנו כי הדאטה שקיבלנו מעט "בעייתית", איננה זהה באיכותה, תכונותיה או ברמתה לדאטא שתייגנו בחלק הראשון, ואף מגדילה את חוסר האיזון בין גודל המחלקות. כל אלו עלולים להקשות מאוד בבניית מודל קוהרנטי והפקת משמעויות רלוונטיות ללמידה העמוקה.

אימנו את המודלים על הדאטא עם התיוגים החדשים, במקרים מסוימים קיבלנו תוצאות נמוכות יותר עם אותם פרמטרים, ובמקרים אחרים תוצאות כמעט זהות לאלו שקיבלנו קודם לכן. עם זאת, הבנו כי התיוגים החדשים שנוספו מעמיקים את הפער וחוסר האיזון בין המחלקות (הדאטה החדשה הכילה בעיקר גלים עם ציון 0), ולא משפרים בכלל או באופן משמעותי את תוצאות המודלים. מפאת אלה, ובתמיכת החברה, החלטנו לקטלג את התיוגים החדשים כבעייתיים ולהתריע על כך לגורמים האחראים על כך בחברה.

על כן המודלים המצטיינים שלנו שנציג בהמשך מתבססים על הדאטאבייס שמורכב מהתיוג הראשוני שביצענו יחד עם גורמים מהחברה, וזאת כדי שנוכל להפיק את המיטב מהלמידה ומהדאטה המורכבת שקיבלנו.

ניסויים ומודלים

בשיתוף פעולה עם החברה ובפרט עם המנחה שלנו ליאור, בנינו בייסליין שמבוסס על [קוד המתאים ללמידת הדאטא שלנו](#).

הרצנו מספר מודלים, וביצענו מעקב אחר הריצות. בכל פעם שינינו את אחד או יותר מהפרמטרים - סוג המודל, מספר האפוקים, או סוג פונקציית השגיאה.

שם המודל	הסבר קצר	השראה
CNN	מודל זה הוא סוג ספציפי של רשת עצבית הנקראת רשת עצבית קונבולוציונית (CNN). הוא מיועד לעיבוד ולמידה של תכונות מנתונים בעלי מבנה תלת מימדי, כגון תמונות או סרטונים. בין היתר, מודל מסוג זה יכול להיות יעיל גם בניתוח דפוסים זמניים ב time series, כמו במקרה שלנו. על ידי התייחסות לממד הזמן כרוחב או גובה של נתוני הקלט, ה-CNN יכול ללמוד דפוסים ותלויות בסדרת הזמן.	
CNN_LSTM	מודל זה משלב שכבות Convolutional Neural Network (CNN) וזיכרון לטווח קצר (LSTM) לעיבוד נתונים עוקבים. ה-CNN מחלץ פיצ'רים רלוונטיים, וה-LSTM לוכד תלות ארוכת טווח.	https://www.nature.com/articles/s41598-021-92997-0
Transformer_CNN	מודל זה משלב Transformer ו-CNN לעיבוד נתונים רציפים, כמו במקרה שלנו. Transformer הוא סוג של ארכיטקטורת רשת עצבית שמשמשת בעיקר במשימות sequence to sequence. בשילוב בין השניים, ה-Transformer מזהה תלות, ו-CNN אחראי על חילוף הפיצ'רים.	
ClassifierCNN	מודל זה הוא רשת עצבית Convolutional Neural Network (CNN) לסיווג אודיו. למעשה השתמשנו במודל לחיזוי אודיו משום שסיגנלי אודיו מאוד מזכירים את הסיגנלים שהדאטא שלנו מכיל. המודל מורכב ממספר בלוקים קונבולוציוניים ואחריהם מסווג ליניארית. ה-CNN מחלץ את הפיצ'רים, והשכבה הליניארית חוזה את הלייבלים.	https://towardsdatascience.com/audio-deep-learning-made-simple-sound-classification-step-by-step-cebc936bbe5

משתנים נוספים ששינינו בכל ריצה:

- מספר האפוקים: בחנו את המודלים עם 500 או 100 אפוקים. ככל שנגדיל את מספר האפוקים הציפייה היא לקבל תוצאות טובות יותר, משום שלמודל יש יותר הזדמנויות למצוא את המשקולות הטובות ביותר שיפיקו את הציון הטוב ביותר. עם זאת, חלק מהמודלים בעלי זמן ריצה ארוך מאוד ולכן לא את כולם הרצנו עם 500 אפוקים. בנוסף, הציפייה לקבל ציונים גבוהים יותר עם מספר אפוקים גבוה יותר, לא בהכרח תתממש, לכן השתמשנו גם ב-100 אפוקים וראינו את ההבדלים בין הריצות.

- פונקציות השגיאה:

- Focal loss

- Focal loss considering the Weight of each label

- Cross Entropy

- פונקציית התוצאה: 1f

סיכום שלב המודלים ותוצרים רלוונטיים

בחרנו להתמקד ב-3 מודלים שהפיקו עבורנו בשלב הראשון את הציונים הגבוהים ביותר, ולהמשיך להריץ ניסויים על הדאטה הקיימת, תוך חלוקת הדאטה לtrain וtest.

המודלים הנבחרים הם:

1. **ClassifierCNN**

2. **CNN-LSTM**

3. **TRANSFORMER**

לאחר שראינו שהציונים שקיבלנו עבור כל מודל ופרמטרים מתכנסים לציון די דומה, יצרנו מחברת collab חדשה בהמלצת גורמי החברה, והפעם ביצענו סיווג בינארי.

על כן, כחלק מתוצרי הפרויקט, אנו מציגים שתי מחברות collab המציגות שני סוגי קלפיסיקציה:

א. 3 מחלקות (0,1,2) כאשר מיפינו את הציונים 4,5 ל-2, 2,3 ל-1, ו0,1 ל-0.

ב. 2 מחלקות, בינארי (0,1). כאשר מיפינו את הציונים 3,4,5 ל-1, ו0,1,2 ל-0.

בהתאמה, העמודים הבאים יתבססו על מודלים אלו:

3 מחלקות

מתוך טבלת מעקב של הניסויים (צילום מסך):

Expiriment	model	loss function	number of epochs	score function	best score	best loss	which epoch generated the best score?
19	Classifie rCNN	Cross Entropy	500	f1	0.7378	0.6174	347
20	Classifie rCNN	Cross Entropy	500	f1	0.7389	0.6471	258
21	Classifie rCNN	Cross Entropy	100	f1			
22	Classifie rCNN	Cross Entropy	20	f1	0.6708	0.7017	20
23	Classifie rCNN	Focal Loss	50	f1	0.7072	0.2374	42
24	Classifie rCNN	Cross Entropy	50	f1	0.6939	0.2464	24
25	Classifie rCNN	Focal Loss	50	f1	0.7227	0.2983	46
26	Classifie rCNN	Cross Entropy	50	f1	0.7204	0.3025	46
27	Classifie rCNN	Cross Entropy	500	f1	0.7374	0.8061	476
28	Classifie rCNN	Focal Loss	100	f1	0.7183	0.2983	77
29	Classifie rCNN	Cross Entropy	100	f1	0.7194	0.8139	67
30	Classifie rCNN	Cross Entropy	500	f1	0.7335	0.8035	415

התוצאה הטובה ביותר שקיבלנו (f1) היא בעזרת המודל ClassifierCNN:
החיזוי הטוב והאמין ביותר קיבל ציון של 73.35% (Validation)

===== CV =====

Score: 0.7335

מדדים נוספים שיצאנו בריצה זו (test):

confusion matrix/roc curve

```


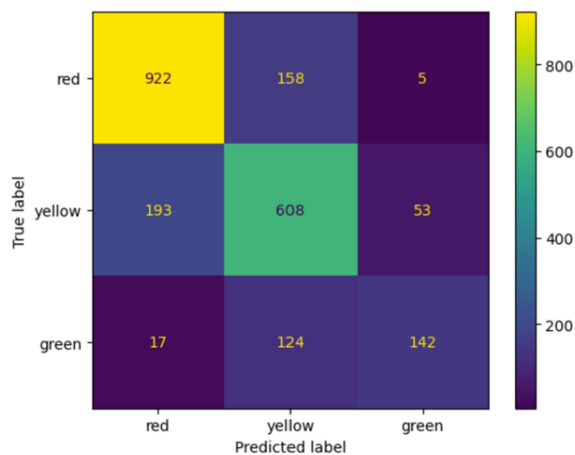
classification_report
precision    recall  f1-score   support

   red       0.81     0.85     0.83     1085
  yellow     0.68     0.71     0.70     854
   green     0.71     0.50     0.59     283

 accuracy          0.74          0.75     2222
  macro avg       0.74     0.69     0.71     2222
 weighted avg     0.75     0.75     0.75     2222

```

Confusion matrix



2 מחלקות (בינארי)

Expiriment	model	loss function	number of epochs	score function	best score	best loss	which epoch generated the best score?
1	CNN_LSTM	BCELoss	50	f1	0.8596	0.35	37
2	ClassifierCNN	BCELoss	100	f1	0.857	0.3548	96
3	ClassifierCNN	BCELoss	100	f1	0.8637	0.3501	96
4	TransformerCNN	BCELoss	100	f1	0.8385	0.4246	85
5	ClassifierCNN	BCELoss	100	f1	0.8586	0.3548	94
6	TransformerCNN	BCELoss	500	f1	0.8395	0.4098	47
7	CNN_LSTM	BCELoss	100	f1	0.8644	0.3359	29
8	ClassifierCNN	BCELoss	500	f1	0.8599	0.3562	145

התוצאה הטובה ביותר שקיבלנו (f1) היא בעזרת המודל CNN_LSTM:
החיזוי הטוב והאמין ביותר קיבל ציון של 86.44% (Validation).

מדדים נוספים עבור ריצה זו (test):

confusion matrix/ roc curve

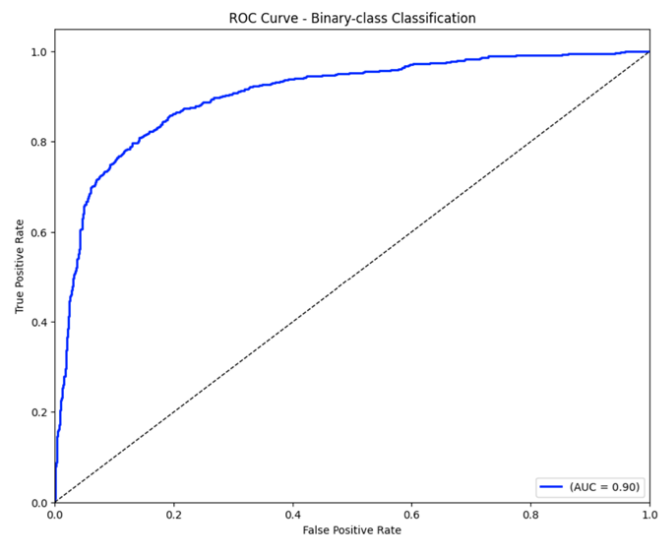

```

classification_report
precision    recall  f1-score   support

   red       0.88     0.93     0.91     1573
  green       0.81     0.70     0.75      649

 accuracy          0.86     2222
 macro avg          0.85     2222
 weighted avg       0.86     2222
  
```

Confusion matrix



5. הצעות לפיתוח עתידי ותובנות להמשך

במהלך העבודה על הפרויקט גיבשנו מספר מסקנות שיעזרו לייעל את המערכת, לשפר את אופן האבחון ואת דיוק החיזוי:

שלב ראשוני, איסוף דאטא איכותי ועיבודו-

- יש לאסוף נתונים גם מ"פציינטיים"/"נסיינים" שאינם חולים פוטנציאליים בהכרח ובסביבת עבודה רגועה על מנת שהחיישנים יוכלו להפיק תוצרים פחות רועשים.
- יש לעבד את הדאטא שנאסף מהחיישנים ולבצע סינון רעש מיותר ומחיקה חכמה של ניסויים שלא ניתן לפרש אותם בצורה ברורה (למשל השניות שנספרות בין כל מדידה) וזאת כדי שעבודת התיוג העתידית תהיה יעילה יותר.

שלב שני, תהליך התיוג והציינון-

- דאטא בתחום הרפואה נוטה להיות מאוד רועשת וקשה לאמוד אותה בעין לא מקצועית, ולכן אחת הבעיות העיקריות בלימוד המודל נבעה כתוצאה מתיוג סובייקטיבי מדי של כל אחד מהממייגים (הסטודנטים) מה שגרם לשונות גבוהה וחוסר אחידות ועל כן:
- על החברה להגדיר קריטריונים ברורים ומדויקים של מהו סגמנט שמתאר בצורה מצוינת גל דופק/אקו לב, נוסף על כך אנו ממליצים לעשות "יישור קו" מערכתי וקפדני עם כל מי שמתעסק בתיוג.
 - פעולת התיוג צריכה להתבצע באופן קוהרנטי, ע"י אדם אחד בלבד או ע"י מספר אנשים שיתייגו את אותם הגלים, ולבסוף ציון גל יקבע על פי ממוצע הציונים שיתקבל (ליצירת "מהימנות בין שופטים").
 - ניתן לבחון את האופציה של למקד מראש את הקטלוג באופן מצומצם יותר, במקום 0 עד 5, ולצמצם את מספר המחלקות שגם ככה יפלו במהלך עיבוד הדאטא בקוד.

שלב שלישי, מודלים-

המלצתנו היא להמשיך לנסות מודלים מורכבים של למידה עמוקה שידעו לטפל בדאטא הרועשת על ידי יצירת רשת נוירונים ששכבותיה הרבות יוכלו ללמד אותנו על הקשרים שבין הסיגנלים השונים.

נוסף על כך אנו ממליצים להשתמש במתודות משוכללות כגון *spectrogram* אשר משתמשת בטכניקות מתמטיות מורכבות כגון *FFT* שיכולות "לפרק" טוב יותר את התנהגות הגלים וככה נוכל ללמוד טוב יותר את הדאטא באמצעות כלים חזותיים וגם להצליח לאתר בצורה טובה יותר את הנקודות הקריטיות בשינויים של הגלים שיעזרו לנבא התקף לב.

6. סיכום:

העבודה על פרוייקט מסוג זה, בשיתוף מהנדסים, מתכנתים ומנהלים בתעשייה העניקה לנו כלים רבים ונתנה לנו טעימה מהעולם האמיתי עם כלל האתגרים הטמונים בו.

ראשית, במסגרת אופי החברה והתחום בה היא מתעסקת התמודדנו לראשונה עם מערכת לא מוכרת ומושגים מעולם הרפואה שעלינו היה ללמוד ולהפיק מסקנות אופרטיביות לטובת הפרוייקט.

בשלב הראשוני, ביצענו תיוג ידני וסיזיפי של מאות סגמנטים על מנת ליצור את הקרקע של לימוד המודל והדאטא בה נתעסק לאורך כל התקופה. דווקא בשלב הזה, שאינו מאופיין במשימות תכנותיות קלאסיות של קידוד, הקשיים והאתגרים בפיצוח מדויק של ציון הגל (במקשי המקלדת) לימדו אותנו רבות על המערכת ועל הרעיון המרכזי של הטכנולוגיה בה החברה מתעסקת שהיא כאמור, ניבוי מוצלח של התקף לב וזיהוי מוקדם של שינויים פיזיולוגיים בלב האדם.

לאחר שייבאנו את התוצרים משלב התיוג, למדנו על בשרנו את אתגר הדאטא המורכבת ו"הרועשת", ואת החשיבות של איסוף דאטא איכותי ועיבוד דאטא קפדני שלאחריה. העבודה מול המפתחים בחברה הייתה מרתקת ומלמדת כאחד, צפינו כיצד התחום של למידת מכונה מהשלב האקדמי עד לפרקטיקה בתעשייה, היא "ממלכת אי הוודאות" שדוגלת גם בניסוי ותהייה על מנת להתקרב ככל שניתן ללימוד מודל מוצלח.

לאורך הפרוייקט, יישמנו את החומר שלמדנו במסגרת התואר באופן הפרקטי ביותר. העבודה השוטפת במחברת ה-Collab הייתה זהה במסגרתה לפרוייקטים האקדמיים שעשינו בניתוח נתונים ולמידת מכונה. נוסף על כך, חווינו את החשיבות של למידה עצמאית ומציאת פתרונות יצירתיים ממשאבים חיצוניים. נעזרנו במדריכים ופורומים שונים כדי להמשיך ולמצוא מודלים חדשים שיתאימו לסוג הדאטא שלנו, ידענו לאזן את היעילות של ChatGPT מול האינפורמטיביות שאפשר לינוק ממהנדסים מקצועיים ומנוסים.

כל אלו הינם כלים חשובים וקריטיים שישמשו אותנו בעתיד לביצוע תפקידים מגוונים בתעשייה: מניהול והנעה של פרוייקט גם בתחומים לא מוכרים עד להעמקה ופיתוח אלגוריתמים וטכניקות מתמטיות מורכבות להתמודדות עם דאטא מגוונת במיוחד.

לסיום, אנחנו מודים לחברת Avertto על המעטפת הלימודית הנוחה והסבלנות שאפיינה כל כך את המנחים בצוות הפיתוח: ליאור טולדנו, אורי שריקי, סמואל וד"ר הלה בן פזי שליוו אותנו לאורך כל התקופה. העבודה במחציתם הייתה חוויה לימודית, מאתגרת ומהנה ושמחנו להיות חלק מכם.

7. לוח זמנים:

תג"ב	פירוט (2-3 שורות)	אבן דרך
12.1.23	גאנט עבודה ואחריות הגשת דוח תכנית עבודה	הורדת משימה ברורה ולו"ז
30.3.23	הגדרת סביבת עבודה מתאימה ולמידת ממשק התיוג	למידת ממשק ה-GUI + תיוג הדאטה חלק א
	תיוג 600 קיטועי זמן כל אחד במערכת GUI שנבחרה עפ"י קריטריונים שנקבעו ע"י גורמים מקצועיים בחברה	
1.4.23	זום סיכום ביניים עם גורמים מהחברה	בקרה וסיכום ביניים אחרי 600 תיוגים
1.6.23		הגשת דו"ח מעקב
25.6.23	תיוג 900 קיטועי זמן נוספים	תיוג הדאטה חלק ב
25.7.23	אימון המודל- השוואה ובחינת מס תוצאות ורשתות הגדרת הייפר-פרמטרים שונים למודלים ובחינתם	אימון הרשת ובחינת המודל
10.9.23	הערכת טיב המודל על פי קריטריונים וציונים שיוגדו בצורה שוטפת ע"י החברה	הערכת המודל
1.10.23		תאריך יעד להגשת הפוסטר וסיום הפרויקט
		מפגש הצגת הפרויקט

